

- 수치적 modeling.

- 한 개의 종속 변수, 한 개 이상의 독립변수

- 두 변수는 작은 것!

- 가장 간단: 직선형의 함수 $y=ax+b$

- 직선 $y=ax+b$

종속 변수의 값

- 직선이 지평 선의 관계는 가장 잘 설명할 수 있도록 a, b 값을 찾는 것.

- cost function

- 종속변수 (containing Variable): 모델은 데이터만으로도 종속변수에 영향을 줌

- 문제: 직선형 → 학습

정답

- 회귀분석의 종류: 종속변수가 연속: 회귀분석, 이산: 분류분석
종속변수가 범주: 분류, 독립변수가 연속: 회귀분석, 이산: 분류

- 회귀식 $y = wx + b$
종속 변수, 독립 변수

회귀분석 결과 < 모델이 데이터에 얼마나 잘 맞나? > 검증
종속변수 변화 → 종속변수 변화

- 공식: x_1, x_2, \dots, x_n, y

- 다중 공선성: 하나의 독립변수가 여러개의 독립변수로 예측
→ 회귀 계수 자체가 의미가 없어짐

- VIF로 다중공선성 진단

VIF > 5 or 10

상관관계 + 분산분석 → 가중치 분석


$$\text{Cost}(w) = \frac{1}{2n} \sum_{i=1}^n (w x^{(i)} - y^{(i)})^2$$

$$w=2, \text{Cost}(w) =$$

X	Y
2	2
3	3

$$\frac{1}{2} \left((2-2)^2 + (4-2)^2 + (6-3)^2 \right)$$

$$= \frac{1}{2} (0 + 4 + 9) = \frac{13}{2}$$




Gradient descent
L이 0이 되면
dw/dw = 0

Cost-function (= loss function)

- Minimize Cost-function
- Gradient descent is used many minimization methods
- For a given cost-function, $\text{Cost}(w, b)$, it will find w, b to minimize cost
- It can be applied to more general function: $\text{Cost}(w_1, w_2, \dots)$

How it works?



- Start with initial guesses
- Start at 0,0 (or any other value)
- Keeping changing w and b a little bit to try and reduce $\text{Cost}(w, b)$
- Each time you change the parameters, you select the gradient which reduces $\text{Cost}(w, b)$ the most possible
- Repeat
- Do so until you converge to a local minimum
- Has an interesting property
- Where you start can determine which minimum you end up

$$w := w - \alpha \left(\frac{\partial}{\partial w} \text{cost-function} \right)$$

왜 이렇게? 역행진 구하기 위함? 음... 반전으로

Formal definition

$$\text{cost}(W) = \frac{1}{m} \sum_{i=1}^m (W x^{(i)} - y^{(i)})^2$$




$$\text{cost}(W) = \frac{1}{m} \sum_{i=1}^m (W x^{(i)} - y^{(i)})^2$$

미분하여 계산함.

Formal definition

$$\text{cost}(W) = \frac{1}{2m} \sum_{i=1}^m (W x^{(i)} - y^{(i)})^2$$



기울기 작아짐.

$$w := w - \alpha \left(\frac{\partial}{\partial w} \text{cost}(W) \right)$$

cost함수는 w에 대해 미분

Formal definition

$$W := W - \alpha \frac{\partial}{\partial W} \frac{1}{2m} \sum_{i=1}^m (W x^{(i)} - y^{(i)})^2$$

$$W := W - \alpha \frac{1}{2m} \sum_{i=1}^m 2(W x^{(i)} - y^{(i)}) x^{(i)}$$

$$W := W - \alpha \frac{1}{m} \sum_{i=1}^m (W x^{(i)} - y^{(i)}) x^{(i)}$$

learning weight (α)
(학습률)
일반적으로 0.1 ~ 0.001

구분은 중요함